Universidad Nacional de Loja

Integrantes

Juan Alberto Calopino Martínez

Fecha:

18 de octubre, 2026

Curso:

Ingeniería en Computación - Quinto ciclo

Docente:

José Guaman

Materia:

Simulación

Periodo:

2026-2027

1. Datos generales

Universidad	Universidad Nacional de Loja
Carrera	Computación
Asignatura	Simulación
Ciclo	Quinto
Unidad	U1: Introducción a la Simulación
Resultado de aprendizaje	R1. Aplica análisis estadísticos de los datos de la simulación para mejorar la calidad de los resultados, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	03
Título de la práctica	Simulación de un sistema de líneas de espera M/M/1 mediante SimPy
Docente	José O. Guamán Q.
Integrantes del grupo	Wilson Patricio Palma Samaniego; Juan Alberto Calopino Martinez; Bryan Gustavo Troya Velez
Autor del informe	Juan Alberto Calopino Martinez
Tipo de entrega	Informe individual
Fecha	18 de octubre de 2026
Lugar	Aula
Tiempo planificado	3 horas

2. Resumen

En este informe presento los resultados de mi ejecución de la aplicación que simula una línea de espera M/M/1 con SimPy. Calculé los valores teóricos de L, Lq, W y Wq para los tres escenarios de la guía ($\lambda = 2.0$, 2.5 y 2.9, con $\mu = 3.0$) y los comparé con lo obtenido en la simulación, usando **1000 clientes** y la **semilla 42** en cada escenario. También incluyo las gráficas de la evolución de la cola y de la distribución de los tiempos de espera, el análisis del comportamiento del sistema y las respuestas a las preguntas de control. Como se esperaba, al acercarse λ a μ aumentaron la utilización, el tamaño de la cola y el tiempo de espera.

3. Introducción

Las líneas de espera aparecen en la atención en ventanillas, los centros de llamadas o los servidores informáticos: los clientes llegan en momentos aleatorios y deben esperar si el servidor está ocupado. Cuando la tasa de llegada se acerca a la capacidad de atención, la cola y el tiempo de espera crecen con rapidez [1], [2].

La teoría de colas ofrece fórmulas para calcular el número promedio de clientes, el tiempo en el sistema y la utilización del servidor [2], [3]. La simulación de eventos discretos las complementa, porque permite observar cómo cambia el sistema a lo largo del tiempo [4]. En esta práctica se estudia el modelo M/M/1 (llegadas de Poisson, servicio exponencial y un solo servidor con atención FIFO) y se comparan sus valores teóricos con los de una simulación hecha con SimPy.

El código de la aplicación se desarrolló de manera grupal. En este informe presento mi ejecución particular, mis tablas, mis gráficas y el análisis que realicé de forma individual.

4. Objetivos

4.1 Objetivo general

Analizar el comportamiento de un sistema de líneas de espera M/M/1 simulado con Python y SimPy, comparando las métricas teóricas con las obtenidas en la simulación.

4.2 Objetivos específicos

- Calcular los valores teóricos de la utilización ρ y de las métricas L, Lq, W y Wq para los tres escenarios de la guía.
- Presentar las gráficas del comportamiento de la cola y de los tiempos de espera obtenidas en mi ejecución.
- Comparar los resultados teóricos y simulados mediante tablas y gráficas.
- Analizar cómo cambia el sistema cuando λ se aproxima a μ y responder las preguntas de control.

5. Marco teórico

5.1 Modelo M/M/1

En la notación de Kendall, la primera M indica llegadas de Poisson (tiempos entre llegadas exponenciales), la segunda M indica tiempos de servicio exponenciales y el 1 indica un único servidor [3]. Los clientes se atienden en orden de llegada (FIFO). Los parámetros del modelo son λ (tasa media de llegada), μ (tasa media de servicio) y ρ (utilización del servidor).

5.2 Métricas teóricas

Para que el sistema sea estable debe cumplirse $\lambda < \mu$, es decir, $\rho < 1$. En ese caso las métricas son [2], [3]:

Métrica	Símbolo	Fórmula
Utilización del servidor	ρ	$\rho = \lambda / \mu$
Clientes promedio en el sistema	L	$L = \lambda / (\mu - \lambda)$
Clientes promedio en la cola	Lq	$Lq = \lambda^2 / [\mu(\mu - \lambda)]$
Tiempo promedio en el sistema	W	$W = 1 / (\mu - \lambda)$
Tiempo promedio de espera en la cola	Wq	$Wq = \lambda / [\mu(\mu - \lambda)]$

Estas métricas se relacionan mediante la ley de Little: $L = \lambda W$ y $Lq = \lambda Wq$ [5]. Nota: la utilización es $\rho = \lambda/\mu$ (no μ/λ), de modo que un valor cercano a 1 indica un servidor ocupado casi todo el tiempo.

6. Materiales y herramientas

De acuerdo con la guía de la práctica [1], se utilizaron las siguientes herramientas:

- **Python 3** como lenguaje de programación.
- **SimPy** para la simulación de eventos discretos.
- **NumPy** para la generación de tiempos aleatorios.
- **Matplotlib** para las gráficas.
- **Streamlit**, con la que se construyó la interfaz web local que utilicé para ejecutar los escenarios (visible en las capturas de este informe).

7. Metodología

La simulación genera, para cada cliente, un tiempo entre llegadas exponencial de media 1/λ. Al llegar, el cliente solicita el servidor; si está ocupado espera su turno y, cuando queda libre, recibe el servicio, cuyo tiempo es exponencial de media 1/μ [1], [6]. La aplicación registra la llegada, el inicio del servicio, la espera, el servicio y la salida de cada cliente, y a partir de esos registros calcula las métricas simuladas.

Para mi ejecución utilicé el panel de configuración de la aplicación con **1000 clientes** y **semilla aleatoria 42**; la misma semilla se aplica a cada escenario. Los tres escenarios de la guía son:

Escenario	λ	μ	Condición	ρ = λ / μ
1	2.0	3.0	Sistema estable	0.6667
2	2.5	3.0	Mayor utilización	0.8333
3	2.9	3.0	Cerca de la saturación	0.9667

Los intervalos de observación (desde 0 hasta la salida del último cliente) que mostró la aplicación fueron [0, 497.642], [0, 391.771] y [0, 350.523] unidades de tiempo para los escenarios 1, 2 y 3, respectivamente.

8. Resultados

8.1 Valores teóricos de L, Lq, W y Wq

Aplicando las fórmulas de la sección 5.2 con μ = 3.0 se obtienen los siguientes valores teóricos. Como ejemplo, para el escenario 2: ρ = 2.5/3 = 0.8333; L = 2.5/(3 − 2.5) = 5; Lq = 2.5²/[3(0.5)] = 4.1667; W = 1/0.5 = 2; Wq = 2.5/[3(0.5)] = 1.6667.

Escenario	λ	μ	ρ	L	Lq	W	Wq
1	2.0	3.0	0.6667	2.0000	1.3333	1.0000	0.6667
2	2.5	3.0	0.8333	5.0000	4.1667	2.0000	1.6667
3	2.9	3.0	0.9667	29.0000	28.0333	10.0000	9.6667

Los valores teóricos coinciden con los que muestra la aplicación en su tabla de comparación (ver Figura 9).

8.2 Comparación entre resultados teóricos y simulados

La siguiente tabla compara los valores teóricos con los obtenidos en mi simulación (1000 clientes, semilla 42).

Escenario	ρ teór.	ρ sim.	Wq teór.	Wq sim.	Lq teór.	Lq sim.	W teór.	W sim.
1	0.6667	0.6933	0.6667	0.7098	1.3333	1.4263	1.0000	1.0548
2	0.8333	0.8941	1.6667	2.2605	4.1667	5.7699	2.0000	2.6108
3	0.9667	0.9926	9.6667	12.0059	28.0333	34.2513	10.0000	12.3538

ρ sim. = utilización simulada; Wq sim. = tiempo promedio de espera simulado; Lq sim. = tamaño promedio de la cola simulado; W sim. = tiempo promedio en el sistema simulado.

La diferencia relativa de la simulación respecto al valor teórico (calculada por mí a partir de la tabla anterior) fue:

Escenario	ρ	Wq	Lq	W
1	+4.0 %	+6.5 %	+7.0 %	+5.5 %

Escenario	ρ	Wq	Lq	W
2	+7.3 %	+35.6 %	+38.5 %	+30.5 %
3	+2.7 %	+24.2 %	+22.2 %	+23.5 %

8.3 Evolución del tamaño de la cola

Las gráficas muestran cuántos clientes esperan en la cola a lo largo de la simulación; la línea punteada es el valor teórico de Lq.

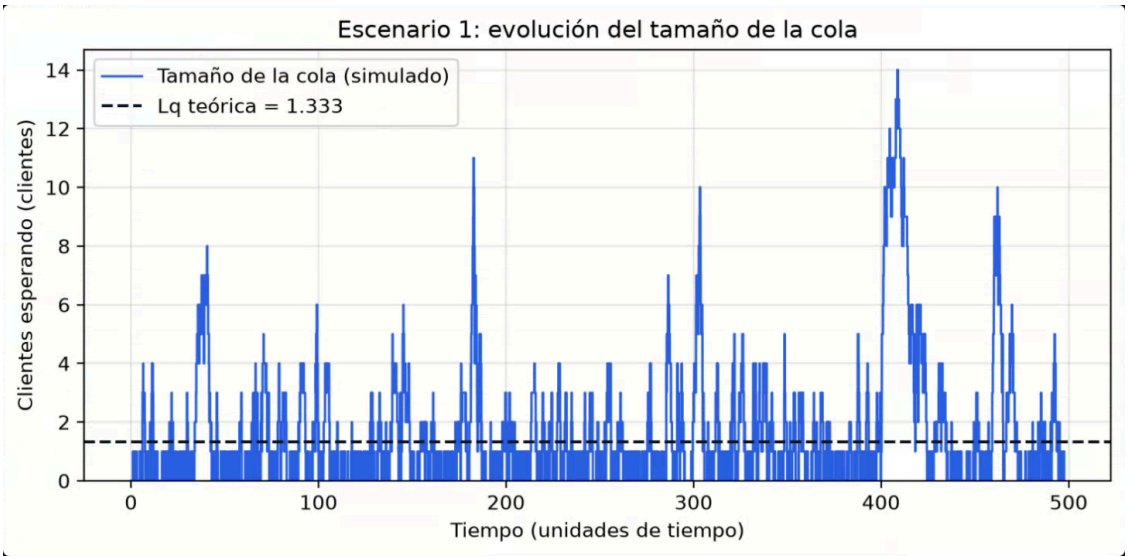


Figura 1. Escenario 1 (λ = 2.0): evolución del tamaño de la cola.

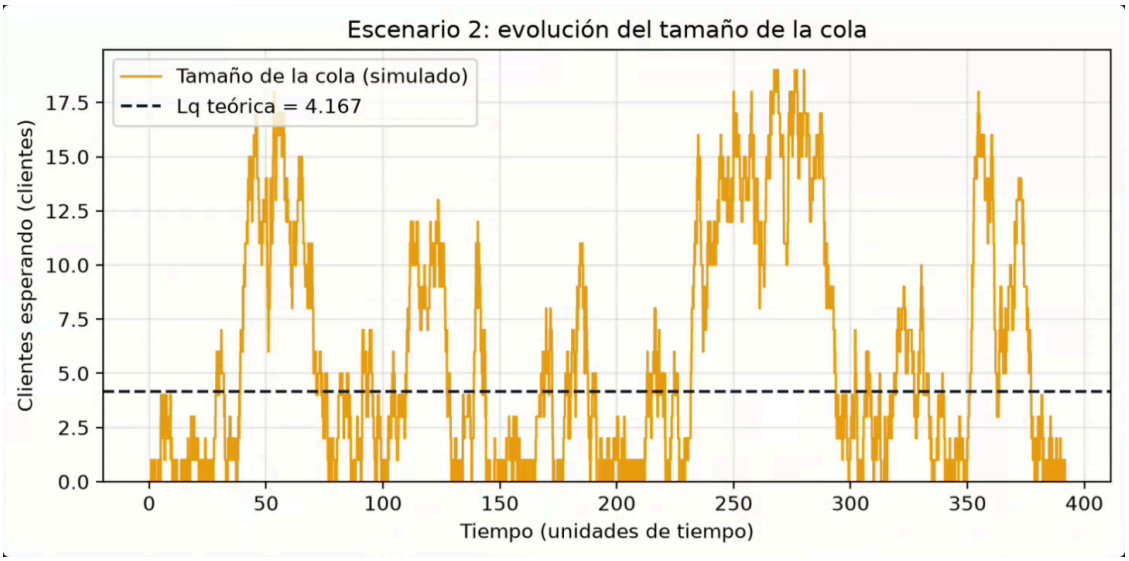


Figura 2. Escenario 2 (λ = 2.5): evolución del tamaño de la cola.



Figura 3. Escenario 3 (λ = 2.9): evolución del tamaño de la cola.

En el escenario 1 la cola se mantiene baja, con muchas oscilaciones pequeñas y algunos picos aislados (el mayor llega a 14 clientes). En el escenario 2 los picos son más frecuentes y llegan hasta unos 19 clientes. En el escenario 3 la cola crece desde cero hasta valores entre 20 y 60 clientes y permanece alta durante casi toda la simulación; solo baja al final, cuando ya no llegan más clientes y se atiende a los que quedaban.

8.4 Distribución de los tiempos de espera

Los histogramas muestran cómo se reparten los tiempos de espera de los 1000 clientes. La línea punteada es la Wq teórica y la línea roja es la Wq simulada.

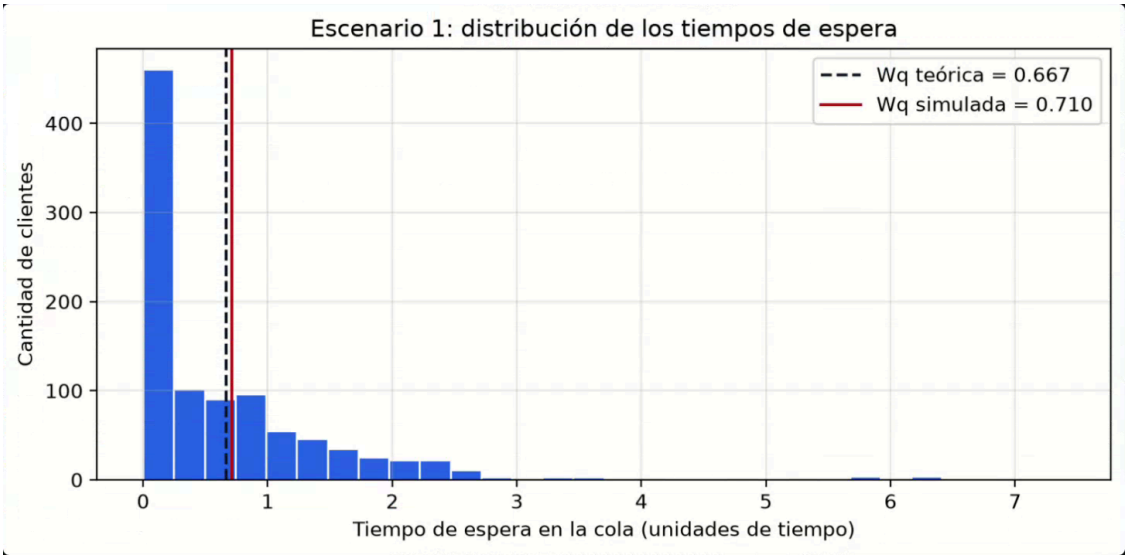


Figura 4. Escenario 1: distribución de los tiempos de espera.

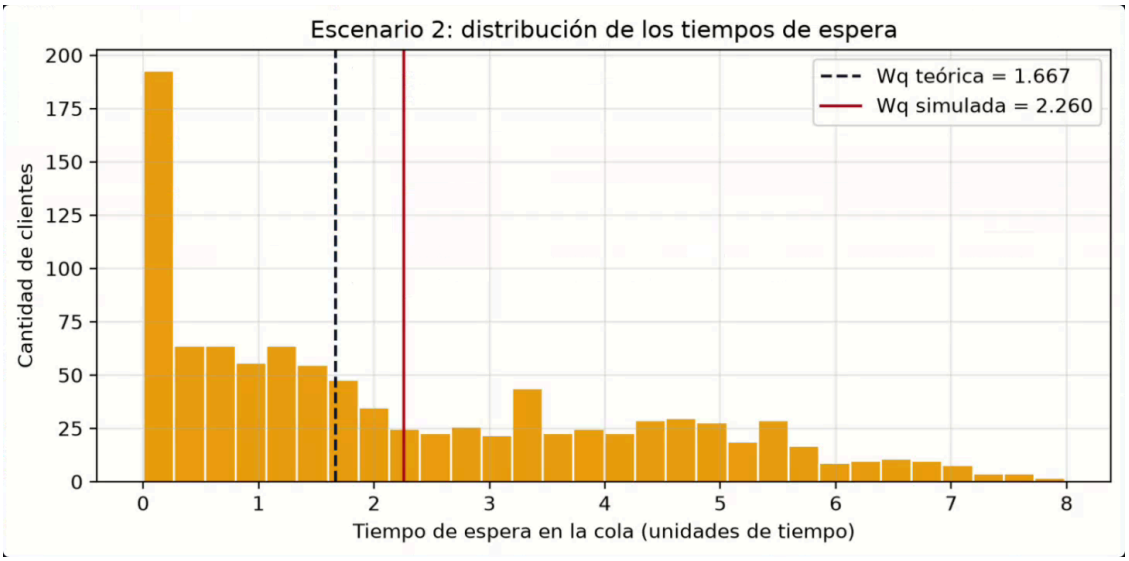


Figura 5. Escenario 2: distribución de los tiempos de espera.

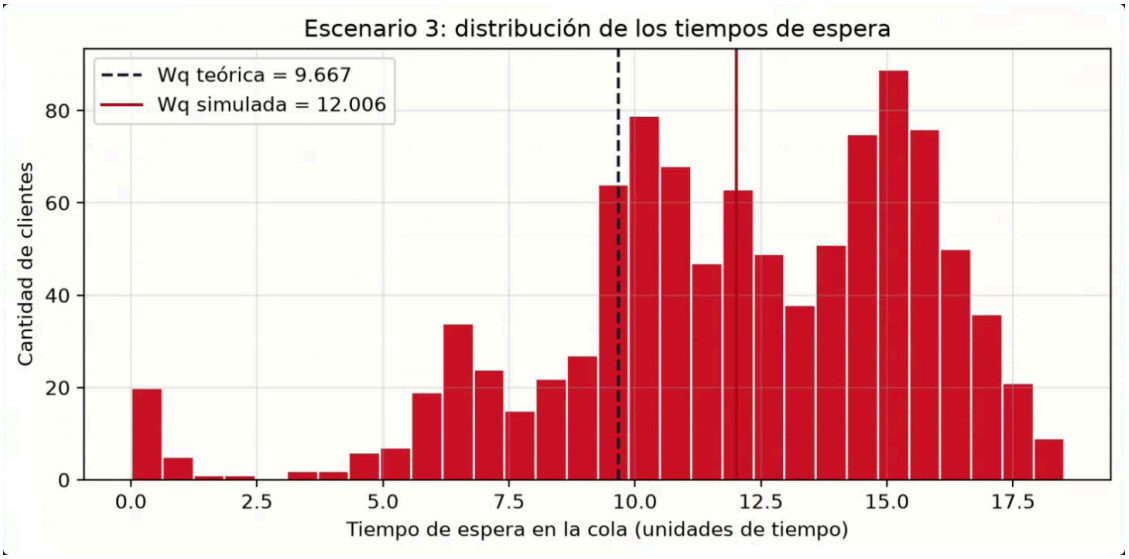


Figura 6. Escenario 3: distribución de los tiempos de espera.

En el escenario 1 la mayoría de los clientes espera muy poco (cerca de 460 esperan menos de 0.2 unidades). En el escenario 2 todavía hay muchos clientes con espera casi nula (cerca de 190), pero aparece una cola larga que llega hasta unas 8 unidades. En el escenario 3 casi nadie espera poco: la mayor parte de los clientes espera entre 7 y 18 unidades de tiempo.

8.5 Comparación entre escenarios

Estas gráficas comparan los valores teóricos y simulados de Wq y Lq en los tres escenarios.

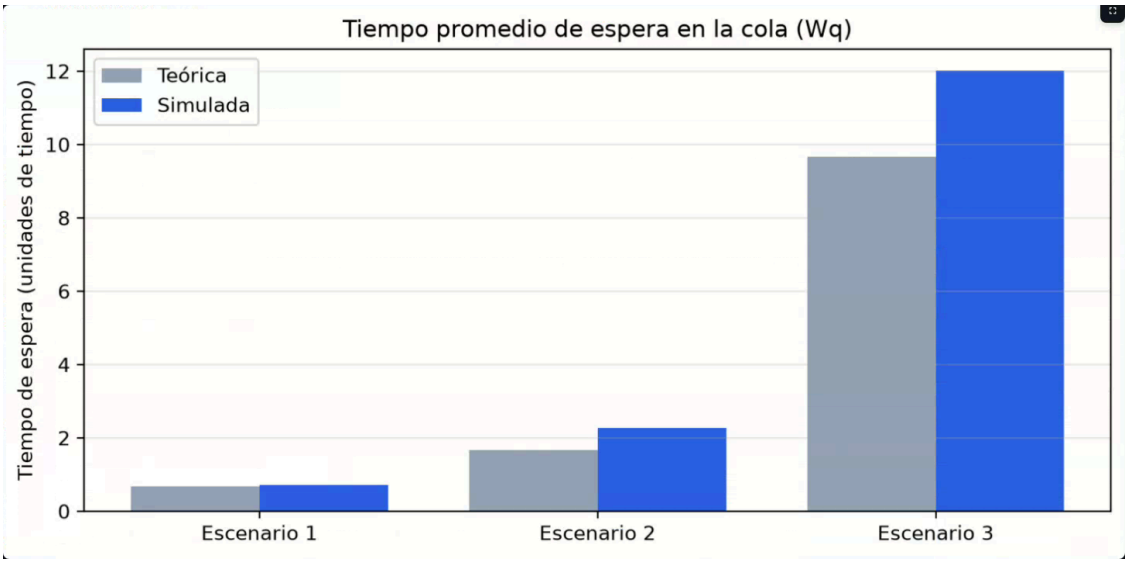


Figura 7. Tiempo promedio de espera en la cola (Wq): teórico frente a simulado.

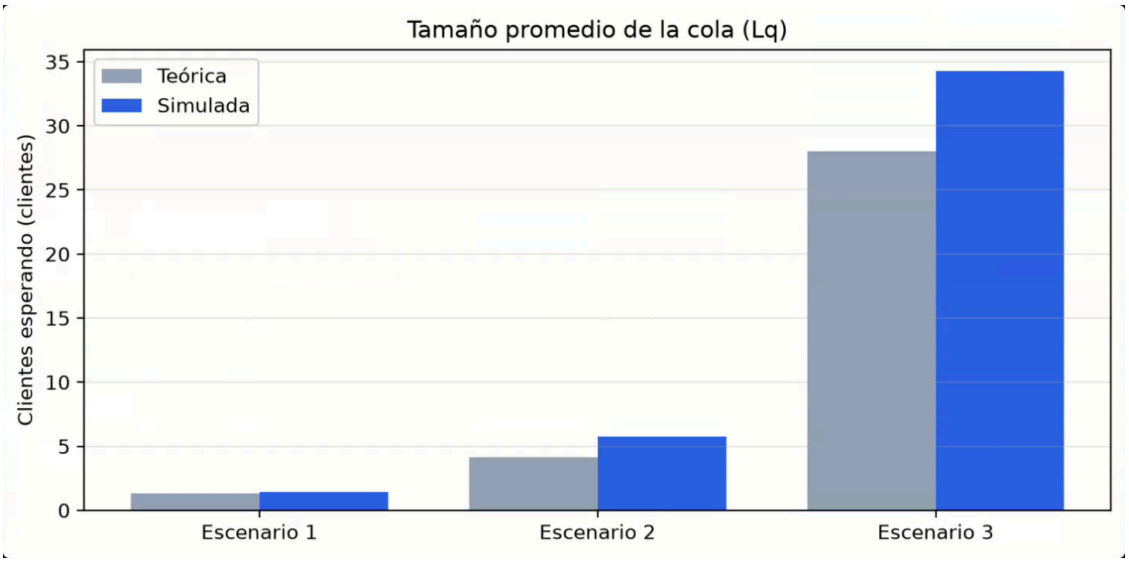


Figura 8. Tamaño promedio de la cola (Lq): teórico frente a simulado.

En ambas gráficas las barras crecen con λ, y el salto del escenario 2 al 3 es mucho mayor que el del 1 al 2. En los tres escenarios la barra simulada quedó por encima de la teórica.

8.6 Evidencia de la interfaz

La captura corresponde a la ejecución de los tres escenarios en una misma corrida, con 1000 clientes y semilla 42, tomada de la grabación de pantalla de mi ejecución.



Figura 9. Resultados de los tres escenarios en la interfaz de Streamlit.

9. Análisis de resultados

Efecto de acercar λ a μ. Lo primero que se observa es que todas las métricas crecen al aumentar λ. Teóricamente, la utilización pasa de 0.6667 a 0.9667 y la espera promedio en la cola sube de 0.6667 a 9.6667 unidades, unas 14.5 veces más, aunque λ solo aumentó de 2.0 a 2.9. Esto ocurre porque el servidor tiene cada vez menos tiempo libre para absorber las variaciones en las llegadas: cerca de ρ = 1, un pequeño aumento de λ produce un aumento muy grande de la cola [2], [3]. La simulación siguió la misma tendencia: Wq simulada fue 0.7098, 2.2605 y 12.0059, y Lq simulada fue 1.4263, 5.7699 y 34.2513.

Diferencias entre simulación y teoría. En mi ejecución los valores simulados quedaron por encima de los teóricos en los tres escenarios. La utilización fue la métrica más cercana (diferencias de 2.7 % a 7.3 %), mientras que Wq y Lq se alejaron más, sobre todo en el escenario 2 (+35.6 % y +38.5 %) y en el 3 (+24.2 % y +22.2 %). Una pista sobre la causa está en la diferencia W − Wq, que es el tiempo promedio de servicio observado: 0.3450, 0.3503 y 0.3479 unidades, frente a 1/μ = 0.3333 del modelo. Como se usó la misma semilla en los tres escenarios, esto indica que en esta corrida los tiempos de servicio generados fueron en promedio entre 3.5 % y 5 % más largos de lo esperado, lo que eleva la utilización efectiva (por ejemplo, 0.8941 simulada frente a 0.8333 teórica en el escenario 2) y, por tanto, las esperas. Cuanto más cerca de la saturación, más se amplifica una desviación pequeña, de modo que el efecto es mayor en los escenarios 2 y 3 que en el 1. Además, las fórmulas describen el comportamiento de largo plazo y la simulación solo usa 1000 clientes y parte con el sistema vacío [1], [4].

Coherencia interna de la simulación. Para comprobar que los resultados simulados son coherentes entre sí apliqué la ley de Little: λ · Wq simulada debería parecerse a Lq simulada.

Escenario	λ · Wq simulada	Lq simulada	Diferencia relativa
1	1.4196	1.4263	0.47 %
2	5.6513	5.7699	2.06 %
3	34.8171	34.2513	1.65 %

Las diferencias son pequeñas (menores al 2.1 %), por lo que las métricas internas de la simulación son consistentes entre sí, aunque difieran de la teoría por el efecto del azar.

Forma de las gráficas. En el escenario 3 la cola nunca llega a estabilizarse en un nivel bajo: sube durante los primeros 100 tiempos aproximadamente, se mantiene entre 20 y 60 clientes y solo cae al final. Su histograma tiene dos zonas (un grupo pequeño de clientes iniciales que casi no esperó y una gran mayoría con esperas largas), lo que muestra que el sistema cerca de la saturación se comporta de forma muy distinta a uno con baja utilización.

Observación final. Con una sola ejecución de 1000 clientes y una única semilla, los valores simulados pueden alejarse bastante de los teóricos cuando ρ es alto. Para obtener promedios más confiables convendría usar más clientes o repetir la simulación con varias semillas.

10. Preguntas de control

¿Qué representa el modelo M/M/1?

Representa un sistema de línea de espera con llegadas de Poisson (tiempos entre llegadas exponenciales), tiempos de servicio exponenciales y un único servidor que atiende a los clientes en orden de llegada (FIFO) [2], [3].

¿Qué representan λ y μ?

λ es la tasa promedio de llegada de clientes al sistema y μ es la tasa promedio de servicio del servidor, ambas en clientes por unidad de tiempo. En la práctica, μ = 3.0 y λ toma los valores 2.0, 2.5 y 2.9 [1].

¿Por qué debe cumplirse λ < μ para que el sistema sea estable?

Porque el servidor debe poder atender, en promedio, más clientes de los que llegan. Si $\lambda \geq \mu$, la cola crece sin límite y no existe un estado estacionario con métricas finitas. En los tres escenarios se cumple, ya que λ llega como máximo a 2.9 y μ es 3.0.

¿Qué significa la utilización ρ?

Es la proporción del tiempo que el servidor permanece ocupado, y se calcula como $\rho = \lambda / \mu$. En mis escenarios fue de 0.6667, 0.8333 y 0.9667 (66.7 %, 83.3 % y 96.7 %) en teoría; en la simulación, 0.6933, 0.8941 y 0.9926.

¿Cuál es la diferencia entre W y Wq?

W es el tiempo promedio total que un cliente permanece en el sistema (espera más servicio), mientras que Wq es solo el tiempo promedio que espera en la cola antes de ser atendido. Por eso W > Wq; en el escenario 3 teórico, W = 10 y Wq = 9.6667, y la diferencia (0.3333) es el tiempo medio de servicio 1/μ.

¿Cuál es la diferencia entre L y Lq?

L es el número promedio de clientes en todo el sistema (los que esperan y el que está siendo atendido), y Lq es el número promedio de clientes que esperan en la cola, sin contar al que está en servicio. La diferencia L − Lq es igual a ρ; por ejemplo, en el escenario 2: 5 − 4.1667 = 0.8333.

¿Por qué SimPy utiliza una distribución exponencial para generar los tiempos?

Porque el modelo M/M/1 supone que los tiempos entre llegadas (llegadas de Poisson) y los tiempos de servicio son exponenciales. Esta distribución representa la variabilidad aleatoria de las llegadas y de la atención, con media 1/λ para las llegadas y 1/μ para el servicio [2], [6].

¿Qué sucede con la cola cuando λ se aproxima a μ?

La utilización se acerca al 100 %, por lo que el tamaño promedio de la cola y los tiempos de espera aumentan considerablemente y además se vuelven más variables. En mi ejecución, Lq simulada pasó de 1.4263 (λ = 2.0) a 34.2513 (λ = 2.9) y Wq simulada de 0.7098 a 12.0059.

¿Por qué los resultados simulados pueden ser diferentes de los resultados teóricos?

Porque la simulación usa valores aleatorios y una cantidad finita de clientes, parte con el sistema vacío y depende de la semilla y del número de réplicas, mientras que las fórmulas describen promedios de estado

estacionario [1], [4]. En mi caso, los tiempos de servicio generados resultaron algo más largos que 1/μ, y la diferencia fue mayor en los escenarios cercanos a la saturación.

¿Qué ocurriría si λ fuera mayor que μ?
El sistema sería inestable: llegarían más clientes de los que el servidor puede atender en promedio, la cola crecería sin límite y los tiempos de espera aumentarían progresivamente. Las fórmulas de L, Lq, W y Wq ya no darían valores finitos válidos, por lo que la aplicación debe rechazar ese caso.

11. Conclusiones

- Los valores teóricos de L, Lq, W y Wq de los tres escenarios son: L = 2, 5 y 29; Lq = 1.3333, 4.1667 y 28.0333; W = 1, 2 y 10; Wq = 0.6667, 1.6667 y 9.6667. Crecen de forma muy acelerada al pasar de ρ = 0.67 a ρ = 0.97.
- La simulación reprodujo la misma tendencia: al acercarse λ a μ aumentaron la utilización, el tamaño de la cola y el tiempo de espera, tal como se esperaba en la guía.
- En mi ejecución (1000 clientes, semilla 42) los valores simulados quedaron por encima de los teóricos: la utilización difirió entre 2.7 % y 7.3 %, mientras que Wq y Lq difirieron entre 6.5 % y 38.5 %. La causa principal fue que los tiempos de servicio generados resultaron en promedio más largos que 1/μ y que una sola corrida finita no reproduce exactamente el estado estacionario.
- La ley de Little se cumplió con diferencias menores al 2.1 %, lo que indica que las métricas simuladas son coherentes entre sí.
- Las gráficas mostraron que, cerca de la saturación (escenario 3), la cola se mantiene alta casi todo el tiempo y la mayoría de los clientes tiene esperas largas.

12. Recomendaciones

- Para escenarios con ρ cercano a 1, aumentar la cantidad de clientes o repetir la simulación con distintas semillas y promediar los resultados, en lugar de basarse en una sola corrida.
- Reportar junto con cada métrica la cantidad de clientes y la semilla utilizadas, para que los resultados puedan reproducirse.
- Como trabajo futuro, ampliar el modelo a varios servidores o a una cola con capacidad limitada y comparar con lo observado en este sistema de un solo servidor.

13. Código y material complementario

Repositorio del código del grupo:

Haga click aquí

14. Declaración de uso de inteligencia artificial

- **Herramienta:** Claude (Anthropic), asistente de inteligencia artificial.
- **Uso:** apoyo para estructurar y redactar este informe y las diferencias porcentuales a partir de los resultados de mi ejecución, además para la corrección de posibles faltas ortográficas.
- **Prompt:**

  Actúa como un Consultor Analista y Experto en Redacción Corporativa. Te proporcionaré los datos de los resultados de mi ejecución y necesito que me ayudes a estructurar, redactar y pulir un informe profesional.

Por favor, realiza las siguientes tareas:

1. CORRECCIÓN Y REDACCIÓN: Corrige cualquier falta ortográfica, gramatical o de puntuación. Mejora la redacción para que tenga un tono formal, profesional, claro y ejecutivo.

2. CÁLCULO Y ANÁLISIS PORCENTUAL: A partir de los datos numéricos que te daré, calcula las diferencias porcentuales (incrementos o disminuciones) entre los resultados obtenidos y las metas/periodos anteriores según corresponda.

3. ESTRUCTURACIÓN: Organiza la información en un formato de informe limpio utilizando la siguiente estructura:

- Resumen Ejecutivo (un párrafo breve con lo más importante).
- Metodología / Datos de Ejecución (tabla o lista con los datos limpios).
- Análisis de Resultados (donde expliques las variaciones y diferencias porcentuales).
- Conclusiones / Próximos pasos (puntos clave de mejora).

- **Verificación personal:** los resultados, las gráficas y las capturas provienen de mi propia ejecución de la aplicación, y revisé el contenido del informe antes de entregarlo.

15. Referencias

[1] J. O. Guamán Q., “Guía de Actividades Práctico-Experimentales Nro. 003: Simulación de un sistema de líneas de espera M/M/1 mediante SimPy,” Universidad Nacional de Loja, Loja, Ecuador, oct. 2026.

[2] L. Kleinrock, Queueing Systems, Volume 1: Theory. New York, NY, USA: Wiley-Interscience, 1975.

[3] D. Gross, J. F. Shortle, J. M. Thompson, and C. M. Harris, Fundamentals of Queueing Theory, 4th ed. Hoboken, NJ, USA: John Wiley & Sons, 2008.

[4] J. Banks, J. S. Carson, B. L. Nelson, and D. M. Nicol, Discrete-Event System Simulation, 5th ed. Upper Saddle River, NJ, USA: Prentice Hall, 2010.

[5] J. D. C. Little, “A proof for the queuing formula: $L = \lambda W$,” Operations Research, vol. 9, no. 3, pp. 383–387, 1961.

[6] Team SimPy, “SimPy: Discrete event simulation for Python,” SimPy Documentation. Disponible en: https://simpy.readthedocs.io/en/latest/